

Data Science and Analytics – PUC-Rio

MVP de Engenharia de Dados

27 de setembro de 2026

Análise da produção de petróleo e gás natural no Brasil

Aluna: Amanda Mariano Bandeira

Matrícula: 4052026000525

Plataforma utilizada: Databricks (free edition)

Fonte de dados: ANP – Agência Nacional de Petróleo, Gás Natural e Biocombustíveis

Período analisado: 01/2021 a 08/2026

Repositório do GitHub: https://github.com/ambarndt/MVP_Engenharia-de-Dados-Amanda-Mariano-Bandeira

Sumário

1. Contexto de Negócios e Perguntas	3
1.1. Contexto de Negócios	3
1.2. Contexto de Dados Brutos	3
1.2.1. Estrutura de Dados	3
1.2.2. Licença de uso	4
1.3. Perguntas de Negócio	4
2. Carga de Dados	4
3. Modelagem e Catálogo de Dados	5
4. Pipeline de Dados	9
5. Qualidade de Dados	10
5.1. Completude	10
5.2. Unicidade	11
5.3. Acurácia	12
5.4. Outliers	12
5.5. Consistência	13
6. Análise de Dados	13
7. Autoavaliação	19

1. Contexto de Negócios e Perguntas

1.1. Contexto de Negócios

O Brasil é um dos maiores produtores de petróleo do mundo, e a descoberta do pré-sal transformou o patamar da produção nacional na última década. Compreender onde essa produção se concentra, quem a opera e como ela se comporta é primordial para qualquer análise de mercado no setor de óleo e gás.

O objetivo desse MVP é construir um pipeline de dados de ponta a ponta que organize os dados públicos de produção por poço da ANP (Agência Nacional de Petróleo, Gás Natural e Biocombustíveis) e permita responder perguntas sobre a realidade da produção brasileira.

1.2. Contexto de Dados Brutos

Os dados brutos são registros da produção mensal por poço e por campo publicados pela ANP (Agência Nacional de Petróleo, Gás Natural e Biocombustíveis) no portal de dados abertos, em formato Excel (.xlsx). Cada linha representa a produção de um poço em um determinado mês e ano. Optei pelo Excel em vista de que o download do CSV do portal limita o número de dados registrados.

1.2.1. Estrutura de dados

O arquivo é uma tabela única. As colunas originais estão listadas abaixo.

Coluna original	Descrição
Período	Mês e ano de referência do dado, no formato (YYYY/MM)
Campo	Nome do campo
Operadora atual	Nome da operadora atual do campo
Poço ANP	Nome do poço produtor
Bacia	Nome da bacia onde o campo está localizado
Localização	Indicação de localização na terra ou no mar
Nome da instalação	Nome da instalação situada no campo
Ambiente	Indicação geológica – terra, mar pós-sal e mar pré-sal
Óleo (bbl/d)	Produção de óleo em barris por dia
Gás Natural (mil m3/d)	Produção de gás natural em mil metros cúbicos por dia
Condensado (bbl/d)	Produção de condensado em barris por dia
Água (bbl/d)	Produção de água em barris por dia

Os dados cobrem o período de janeiro de 2021 a agosto de 2026. O arquivo possui 607.046 linhas.

1.2.2. Licença de uso

Os dados são abertos governamentais brasileiros, regidos pela Lei de Acesso à Informação (nº 12.527/2011) e pela política de dados abertos do governo federal. Uso livre, inclusive acadêmico, desde que citada a fonte (ANP). Fonte: <https://www.gov.br/anp/pt-br/centrais-de-conteudo/dados-abertos/producao-de-petroleo-e-gas-natural-por-poco>.

1.3. Perguntas de Negócio

Levando em consideração o período analisado (2021 a agosto de 2026):

1. Quais campos têm a maior produção de petróleo acumulada?
2. O pré-sal domina a produção nacional? Qual a sua participação percentual no volume de produção total?
3. Qual é o share da produção offshore (mar) em relação à produção total, que inclui a onshore (terra)?
4. Quais as 10 operadoras com o maior share de produção acumulada?
5. Qual é a variação da razão água/óleo das bacias? O que isso sugere sobre o estágio de maturidade de cada uma?
6. Como a produção média evoluiu ao longo dos anos analisados nos dados?

2. Carga de Dados

O arquivo em formato Excel foi baixado do portal de dados abertos da ANP e enviado para um “Volume” no schema bronze do Unity Catalog no Databricks. Como o Spark não lê Excel diretamente, o notebook *01_bronze_ingestao.py* usa pandas (`pd.read_excel`) para abrir o arquivo, converte o resultado para um DataFrame do Spark e grava a tabela Delta *bronze.producao_poco*. A leitura é feita com todas as colunas como texto (a conversão de tipos fica na camada Silver). Essa camada guarda o dado fiel à origem, sem transformar o seu conteúdo. A gravação usa *delta.columnMapping.mode = name*, o que permite manter nomes de colunas com acentos e quaisquer caracteres especiais também.




Figura 1 – arquivo de dados no “Volumes”

```

total = spark.table(f"(CATALOGO).bronze.producao_poco").count()
print(f"Linhas na Bronze: {total:,}")
display(spark.sql(f"SELECT * FROM (CATALOGO).bronze.producao_poco LIMIT 10"))

```

Linhas na Bronze: 607,046

	Período	Campo	Operadora atual	Poço ANP	Bacia	Localização	Nome da Instalação	Ambiente	Óleo (bbl/d)	Gás
1	2022/08	CANTO DO AMA...	3R Potiguar	7-CAM-1401-RN	Potiguar	Terra	Estação Coletora Central de Benfica	Produção Terra	13.721119066451614	1.178929
2	2022/08	CANTO DO AMA...	3R Potiguar	7-CAM-1402D-RN	Potiguar	Terra	Estação Coletora Canto do Amaro E	Produção Terra	35.87200381258065	0.005703
3	2022/08	CANTO DO AMA...	3R Potiguar	7-CAM-1404-RN	Potiguar	Terra	Estação Coletora Canto do Amaro E	Produção Terra	5.670770957741936	0.000901
4	2022/08	CANTO DO AMA...	3R Potiguar	7-CAM-1405-RN	Potiguar	Terra	null	Produção Terra	0	0
5	2022/08	CANTO DO AMA...	3R Potiguar	7-CAM-1406D-RN	Potiguar	Terra	Estação Coletora Canto do Amaro...	Produção Terra	26.90618400322581	0.004277
6	2022/08	CANTO DO AMA...	3R Potiguar	7-CAM-1408-RN	Potiguar	Terra	null	Produção Terra	0	0
7	2022/08	CANTO DO AMA...	3R Potiguar	7-CAM-1409-RN	Potiguar	Terra	Estação Coletora Central de Benfica	Produção Terra	3.2966720283870967	0.062886
8	2022/08	CANTO DO AMA...	3R Potiguar	7-CAM-1410D-RN	Potiguar	Terra	null	Produção Terra	0	0
9	2022/08	CANTO DO AMA...	3R Potiguar	7-CAM-1411D-RN	Potiguar	Terra	Estação Coletora Alto da Pedra B	Produção Terra	12.846835476451613	0.002042
10										

10 rows 4.646s runtime Refreshed 2h ago

Figura 2 – tabela bronze criada, com contagem de linhas

3. Modelagem e Catálogo de Dados

O modelo escolhido foi o **esquema estrela**: uma tabela fato *fato_produção* (poço x mês) cercada de dimensões *dim_campo*, *dim_operadora*, *dim_tempo* e *dim_localizacao*. Os JOINS substituem os textos repetidos pelas chaves das dimensões, deixando a fato enxuta e as consultas mais rápidas.

Camada GOLD

Objetivo desta camada: obter dados prontos para responder perguntas de negócio.

Modelagem em esquema Estrela.

Tabelas criadas: dimensão - quem, onde, quando; fato - medições.




Figura 3 – esquema de fato e dimensões




Figura 4 – camadas bronze, silver and gold no Unity Catalog




Figura 5 – diagrama de Lineage

Catálogo de dados, da tabela Gold:




Figura 6 – catálogo de dados da camada Gold

fato_producao

fato_producao

Open i

Overview

Sample Data

Details

Permissions

Policies

History

Lineage

Insights

Quality

Description

Tabela fato: produção mensal por poço. Fonte: ANP.

Column	Type	Pop...	Comment	Tags	Column mas	
id_tempo	int		Chave para dim_tempo. Origem: JOIN por nome do campo.			
id_campo	int		Chave para dim_campo. Origem: JOIN por nome do campo.			
id_operadora	int		Chave para dim_operadora. Origem: JOIN por nome da operadora.			
id_localizacao	int		Chave para dim_localizacao. Origem: JOIN por localizacao.			
poco	string		Nome do poco. Origem: coluna 'Poco' da ANP.			
vol_petroleo	double		Volume diario de oleo (bbl/d). Origem: coluna Oleo da ANP, texto-> numero na camada Silver.			
vol_gas	double		Volume diario de gas natural (mil m3/d). Origem: coluna 'Gas Natural' da ANP.			
vol_condensado	double		Volume diario de condensado (bbl/d). Origem: coluna 'Condensado' da ANP.			
vol_agua	double		Volume diario de agua (bbl/d). Origem: coluna 'Agua' da ANP.			

Figura 7 – colunas, tipos e descrições de *fato_producao* no Catalog

dim_campo

dim_campo

Open

Overview

Sample Data

Details

Permissions

Policies

History

Lineage

Insights

Quality

Description

Dimensao de campos produtores. Um registro por campo, com bacia, ambiente fisico e classificacao geologica.

Column	Type	Popula...	Comment	Tags	Column masking	
id_campo	int		Chave da dimensao. Gerada por row_number na camada Gold.			
nome_campo	string		Nome do campo produtor. Origem: coluna 'Campo' da ANP, maiusculas na camada Silver.			
bacia	string		Bacia sedimentar. Origem: coluna 'Bacia' da ANP.			
ambiente	string		Localizacao fisica. Origem: coluna 'localizacao' da ANP, normalizada na camada Silver.			
classificacao_geologica	string		Classificacao geologica. Origem: derivada da coluna 'Ambiente' da ANP na camada Silver.			

Figura 8 – colunas, tipos e descrições de *dim_campo* no Catalog

dim_operadora

dim_operadora

Open i

Overview

Sample Data

Details

Permissions

Policies

History

Lineage

Insights

Quality

Description

Dimensao de operadoras. Um registro por operadora atual dos campos.

Filter columns...

Column	Type	Popul...	Comment	Tags	Column masking	
id_operadora	int		Chave da dimensao. Gerada por row_number na camada Gold.			
nome_operadora	string		Nome da operadora atual. Origem: coluna 'Operadora atual' da ANP.			

Figura 9 – colunas, tipos e descrições de *dim_operadora* no Catalog

dim_tempo

dim_tempo

Open i

Overview

Sample Data

Details

Permissions

Policies

History

Lineage

Insights

Quality

Description

Dimensao de tempo. Um registro por combinacao de ano e mes presente nos dados (2021 a 2026).

Filter columns...

Column	Type	Popu...	Comment	Tags	Column maskir	
id_tempo	int		Chave da dimensao. Gerada por row_number na Gold.			
ano	int		Ano de referencia. Dominio: 2021 a 2026. Origem: extraido do 'Periodo' da ANP.			
mes	int		Mes de referencia. Dominio: 1 a 12. Origem: extraido do Periodo da ANP.			

Figura 10 – colunas, tipos e descrições de *dim_tempo* no Catalog

dim_localizacao

dim_localizacao

Open

Overview

Sample Data

Details

Permissions

Policies

History

Lineage

Insights

Quality

Description

Dimensao de localizacao/instalacao. Um registro por combinacao de localizacao e campo.

Filter columns...

Column	Type	Popula...	Comment	Tags	Column masking	
id_localizacao	int		Chave da dimensao. Gerada por row_number na Gold.			
localizacao	string		Localizacao fisica. Origem: coluna 'Localizacao' da ANP.			
campo	string		Nome do campo produtor. Origem: coluna 'Campo' da ANP, maiusculas na camada Silver.			

Figura 11 – colunas, tipos e descrições de *dim_localizacao* no Catalog

4. Pipeline de Dados

Optei por separar o pipeline ETL em notebooks por camada, em vez de concentrar tudo em um único notebook. Essa organização segue a arquitetura **medalhão** (bronze > silver > gold) e mantém cada etapa isolada e fácil de reexecutar.

- *01_bronze_ingestao.py*: extract bruto. Lê o Excel da ANP e mantém a tabela Delta bronze.producao_poco fiel à origem.
- *02_silver_limpeza.py*: transform. Limpa, padroniza e enriquece os dados, gerando *silver.producao_poco*. Principais transformações:
 - Conversão de volumes de texto para número;
 - Padronização de campo, operadora, bacia, localização e instalação em letras maiúsculas;
 - Normalização de “localização” para terra ou mar;
 - Criação da coluna “classificação” a partir da coluna “ambiente” da fonte, criando pre-sal, pos-sal e terra;
 - Extração de *data_ref*, *ano* e *mes* a partir do período (YYYY/MM) da fonte;
 - Nulos de volume convertidos para 0 (zero);
 - Remoção de duplicatas exatas.
- *03_gold_modelagem.py*: modelagem. Criação das dimensões e a fato do esquema estrela na camada gold, e documentação do catálogo no *Catalog*.
- *04_qualidade_e_analise.py*: qualidade + análise. São feitas checagens de qualidade e as análises que respondem às perguntas propostas do MVP.

Cada notebook lê a saída da camada anterior (tabelas Delta gerenciadas), então as camadas se comunicam pelas próprias tabelas do Unity Catalog, e não apenas por variáveis de memórias. Todas as gravações usam *mode(“overwrite”)*, tornando o pipeline idempotente: rodar de novo recria as tabelas do zero, sem duplicação de dados. A ordem de execução é *01_bronze_ingestao.py* > *02_silver_limpeza.py* > *03_gold_modelagem.py* > *04_qualidade_e_analise.py*.



Figura 12 – notebooks separados por camadas no workspace

Todas as tabelas ficam persistidas no Unity Catalog (catálogo workspace, schemas bronze, silver e gold), como evidencia a figura abaixo.




Figura 13 – schemas bronze/silver/gold e suas tabelas no Catalog do Databricks

5. Qualidade de Dados

As verificações foram executadas no notebook *04_qualidade_e_analise.py* sobre a camada Silver (que identificou 607.046 linhas no arquivo base do exercício). Foram testados alguns pontos para avaliar a qualidade dos dados.

5.1. Completude

Investiga o % de nulos por coluna.

Resultados obtidos: volumes, período, campo, bacia e ambientes não resultaram nulos. Operadora resultou em 0,07% de nulos e instalação, 17,2%.

Ação tomada: não existiram nulos de volume. Nulos de texto foram mantidos, pois a ausência de informação é uma resposta válida.

1.1 Completude - proporção de nulos por coluna



Figura 14 – check de completude

5.2. Unicidade

Investiga as duplicadas de poço + mês.

Resultados obtidos: alguns poços apareceram em até 4 registros no mesmo mês. Esses não são duplicatas, e sim a granularidade da fonte, que separa também por pós e pré-sal. Esses dados foram mantidos na base original.

Ação tomada: duplicatas exatas (sem diferenciação pós e pré-sal) foram removidas da base.

1.2 Unicidade - duplicatas de poço + mês




Figura 15 – check de unicidade


5.3. Acurácia

Investiga volumes negativos.

Resultados obtidos: 0 volumes negativos foram localizados.

Ação tomada: nenhuma ação necessária.

1.3 Acurácia - volumes negativos



```
display(spark.sql(f"""
SELECT
SUM(CASE WHEN petroleo < 0 THEN 1 ELSE 0 END) AS petroleo_negativo,
SUM(CASE WHEN gas < 0 THEN 1 ELSE 0 END) AS gas_negativo,
SUM(CASE WHEN condensado < 0 THEN 1 ELSE 0 END) AS condensado_negativo,
SUM(CASE WHEN agua < 0 THEN 1 ELSE 0 END) AS agua_negativo
FROM {CATALOGO}.silver.producao_poco
"""))
```

	petroleo_negativo	gas_negativo	condensado_negativo	agua_negativo
1	0	0	0	0

1 row 1.181s runtime

Figura 16 – check de acurácia


5.4. Outliers

Confere mínimos, máximos, médias e desvios de valores de volume.

Resultados obtidos: resultados coerentes com a base de dados.

Ação tomada: não foram encontrados outliers que necessitassem de remoção.

1.4 Outliers - estatísticas dos volumes (min, max, média, desvio)



```
display(spark.table(f"{CATALOGO}.silver.producao_poco")
.select("petroleo", "gas", "condensado", "agua").summary())
```

	summary	petroleo	gas	condensado	agua
1	count	607046	607046	607046	607046
2	mean	381.135783290118...	17.63015348693081	0.8010771667243191	371.240961006918...
3	stddev	2759.05275115045...	131.01249280421646	18.21492148753411	1373.40662068041...
4	min	0.0	0.0	0.0	0.0
5	25%	0.0	0.0	0.0	0.0
6	50%	3.285167763	0.00326838709677419...	0.0	39.62243085025161
7	75%	12.9878489587096...	0.07883333333333334	0.0	279.5338326233333
8	max	55063.77004302521	3339.387096774194	1458.2268248156665	56772.5245767264...

8 rows 1.290s runtime

Figura 17 – check de outliers

5.5. Consistência

Foi investigada a qualidade da conversão das datas.

Resultados obtidos: 607.046 linhas, zero datas inválidas e anos de 2021 a 2026 consistentes.

Ação tomada: consistência foi validada.

1.5 Consistência



The screenshot shows a Databricks SQL interface. At the top, a Spark SQL query is displayed in a code editor. Below the query, a table of results is shown. The table has four columns: 'total', 'datas_invalidas', 'ano_min', and 'ano_max'. The first row of data shows 607046 total rows, 0 invalid dates, and a date range from 2021 to 2026. The interface also includes a 'See performance (1)' link and a 'Checked for improvements' status.

```
display(spark.sql("""
SELECT
  COUNT(*) AS total,
  SUM(CASE WHEN data_ref IS NULL THEN 1 ELSE 0 END) AS datas_invalidas,
  MIN(ano) AS ano_min, MAX(ano) AS ano_max
FROM (CATALOGO).silver.producao_poco
"""))
```

	total	datas_invalidas	ano_min	ano_max
1	607046	0	2021	2026

1 row 1.291s runtime Refreshed 2h ago

Figura 18 – check de consistência

6. Análise de Dados

As perguntas acima listadas na seção 1.3 foram respondidas com consultas SQL sobre as tabelas da camada Gold.

Importante indicar que o período analisado foi de janeiro de 2021 a agosto de 2026. Todas as perguntas se enquadram na análise apenas desse período.

Pergunta 1: Quais campos têm a maior produção de petróleo acumulada?

No período de 2021 a agosto de 2026, os campos com maior produção acumulada são: Tupi – 56,1 milhões de barris; Búzios – 45,2 milhões de barris; Mero – 19,2 milhões de barris. Os dados são consistentes ao indicarem a concentração do pré-sal na bacia de Santos.

11:53 AM (2s) 17 Python

```

display(spark.sql(f"""
WITH producao_mensal AS (
    SELECT c.nome_campo, c.bacia, f.id_tempo,
           SUM(f.vol_petroleo) AS oleo_dia_no_mes
    FROM {CATALOGO}.gold.fato_producao f
    JOIN {CATALOGO}.gold.dim_campo c ON f.id_campo = c.id_campo
    GROUP BY c.nome_campo, c.bacia, f.id_tempo
)
SELECT nome_campo, bacia,
       FORMAT_NUMBER(SUM(oleo_dia_no_mes), '#,##0.00') AS soma_oleo_total
FROM producao_mensal
GROUP BY nome_campo, bacia
ORDER BY SUM(oleo_dia_no_mes) DESC
LIMIT 10
"""))

```

See performance (1) ✓ Checked for improvements

	nome_campo	bacia	soma_oleo_total
1	TUPI	SANTOS	56,102,521.53
2	BÚZIOS	SANTOS	45,202,284.69
3	MERO	SANTOS	19,227,964.20
4	SAPINHOÁ	SANTOS	10,314,697.04
5	JUBARTE	CAMPOS	9,277,677.85
6	ATAPU	SANTOS	7,732,927.56
7	SÉPIA	SANTOS	7,726,452.61
8	RONCADOR	CAMPOS	7,179,951.71
9	ITAPU	SANTOS	5,961,068.36
10	MARLIM SUL	CAMPOS	5,270,392.71

10 rows 1.850s runtime Refreshed 2h ago

Figura 19 – análise dos campos com maior produção acumulada no período

Pergunta 2: O pré-sal domina a produção nacional? Qual a sua participação percentual no volume de produção total?

Sim. O volume de contribuição do pré-sal na produção total acumulada no período foi de 180,7 milhões de barris. Equivalente a 78% do volume acumulado total.

11:53 AM (2s) 18

```

# Participação da classificação (PRE-SAL / POS-SAL / TERRA) na produção total acumulada
display(spark.sql(f"""
WITH producao_mensal AS (
    SELECT c.classificacao_geologica, f.id_tempo,
           SUM(f.vol_petroleo) AS oleo_dia_no_mes
    FROM {CATALOGO}.gold.fato_producao f
    JOIN {CATALOGO}.gold.dim_campo c ON f.id_campo = c.id_campo
    GROUP BY c.classificacao_geologica, f.id_tempo
),
ranked AS (
    SELECT classificacao_geologica,
           SUM(oleo_dia_no_mes) AS soma_oleo,
           100.0 * AVG(oleo_dia_no_mes) / SUM(AVG(oleo_dia_no_mes)) OVER () AS pct
    FROM producao_mensal
    GROUP BY classificacao_geologica
)
SELECT classificacao_geologica,
       FORMAT_NUMBER(soma_oleo, '#,##0.00') AS soma_oleo_total,
       FORMAT_NUMBER(pct, '#,##0.00') AS pct_do_total
FROM ranked
ORDER BY pct DESC
"""))

```

See performance (1) ✓ Checked for improvements

	classificacao_geologica	soma_oleo_total	pct_do_total
1	PRE-SAL	180,770,866.56	78.13
2	POS-SAL	45,227,295.08	19.55
3	TERRA	5,368,791.07	2.32

3 rows 1.927s runtime Refreshed 2h ago

Figura 20 – análise da participação dos volumes do pré-sal no volume total no período

Pergunta 3: Qual é o share da produção offshore (mar) em relação à produção total, que inclui a onshore (terra)?

O share do volume produzido offshore é de 98% da produção total. Isso confirma que a produção brasileira é majoritariamente offshore.




Figura 21 – análise da participação dos volumes offshore e onshore no volume total no período

Pergunta 4: Quais as 10 operadoras com o maior share de produção acumulada?

As 10 operadoras com maior produção acumulada e seus percentuais no volume total produzido são: Petrobras (88%), Prio Forte (1,76%), Prio Tigris (1,76%), TotalEnergies (1,4%), Shell (0,77%), 3R Potiguar (0,66%), Trident Energy (0,63%), Karoon (0,53%), Brava Energia (0,46%), Prio Bravo (0,43%). Apesar da recente abertura de mercado e da entrada de novos players no E&P (exploração e produção) do Brasil, a Petrobras permanece como a operadora dominante no mercado, sendo a maior detentora de campos produtores e da área do pré-sal brasileiro.

11:53 AM (2s) 22

```

display(spark.sql(f"""
WITH producao_mensal AS (
    SELECT o.nome_operadora, f.id_tempo,
           SUM(f.vol_petroleo) AS oleo_dia_no_mes
    FROM (CATALOGO).gold.fato_producao f
    JOIN (CATALOGO).gold.dim_operadora o ON f.id_operadora = o.id_operadora
    GROUP BY o.nome_operadora, f.id_tempo
),
ranked AS (
    SELECT nome_operadora,
           SUM(oleo_dia_no_mes) AS soma_oleo,
           100.0 * AVG(oleo_dia_no_mes) / SUM(AVG(oleo_dia_no_mes)) OVER () AS pct
    FROM producao_mensal
    GROUP BY nome_operadora
)
SELECT nome_operadora,
       FORMAT_NUMBER(soma_oleo, '#,##0.00') AS soma_oleo_total,
       FORMAT_NUMBER(pct, '#,##0.00') AS pct_do_total
FROM ranked
ORDER BY soma_oleo DESC
LIMIT 10
"""))

```

See performance (1) ✓ Checked for improvements

	nome_operadora	soma_oleo_total	pct_do_total
1	PETROBRAS	206,125,935.19	87.75
2	PRIOR FORTE S.A	4,138,276.81	1.76
3	PRIOR TIGRIS	4,132,305.43	1.76
4	TOTAL ENERGIES EP	3,288,821.87	1.40
5	SHELL BRASIL	1,815,704.95	0.77
6	3R POTIGUAR	1,560,719.64	0.66
7	TRIDENT ENERGY	1,486,521.08	0.63
8	KARDOON BRASIL	1,252,652.13	0.53
9	BRAVA ENERGIA S.A.	1,087,076.79	0.46
10	PRIOR BRAVO	1,006,867.66	0.43

Figura 22 – análise das 10 maiores operadoras em volume de petróleo acumulado no período

Pergunta 5: Qual é a variação da razão água/óleo das bacias? O que isso sugere sobre o estágio de maturidade de cada uma?

A métrica de razão água/óleo pode ajudar a identificar a maturidade de um campo. Não é regra, e essa métrica isolada não prova a maturidade, mas é uma das variáveis que se levam em consideração para tal análise. O resultado encontrado para cada bacia foi:

Camamu – 5.651 (outlier)

Potiguar – 30,4

Sergipe – 22,1

Recôncavo – 21,2

Espírito Santo – 6,0

Alagoas – 3,9

Solimões – 2,4

Campos – 1,8

Paraná – 0,7

Barreirinhas – 0,1

Santos – 0,1

Amazonas – 0,0

Os resultados apoiam a validação de que os campos terrestres (majoritariamente localizados nas bacias de Potiguar, Sergipe, Recôncavo, Espírito Santo, Alagoas) são maduros, e estão atualmente produzindo altos volumes de água. Por outro lado, campos marítimos (majoritariamente bacia de Campos e Santos), são campos descobertos há menos tempo e que ainda não atingiram a mesma maturidade. O resultado obtido em Camamu é um outlier: há pouca produção de óleo, e muita produção de água. Isso infla a razão analisada e não se classifica como uma boa representação de resultados, uma vez que o denominador é muito próximo de 0 (zero).




Figura 23 – análise da razão água/óleo por bacia no período analisado

Pergunta 6: Como a produção média evoluiu ao longo dos anos analisados nos dados?

A produção média no Brasil tem estado em uma crescente nos últimos anos. Saiu de 2,9 milhões de barris de óleo por dia em 2021 para 3,8 milhões de barris de óleo por dia em 2025. Pelos dados analisados, percebe-se uma leve redução em 2024, seguida de uma recuperação nos anos seguintes. Os dados médios para 2026 são parciais e analisados até o mês de agosto. O desempenho dos campos de produção entre os meses de setembro e dezembro pode ter impacto nessa tendência de crescimento.



Figura 24 – análise da produção média ao longo dos anos analisados no Brasil




Figura 25 – plot gráfico da evolução da produção média de óleo no período analisado no Brasil

7. Autoavaliação

Este MVP foi desafiador e importante para meu desenvolvimento. Escolhi utilizar uma base de dados com a qual tenho muita familiaridade, o assunto da indústria de petróleo faz parte da minha vida profissional e esse fator foi com certeza um *plus*, pois conheço os dados e a sensibilidade dos resultados.

Entendo que eu tenha conseguido atingir o objetivo deste MVP, dado que foi possível responder às perguntas propostas nesse trabalho. Criei pipeline completo das camadas bronze > silver > gold no Databricks, e optei por criar os notebooks de forma separada visando à melhor visualização e ao melhor direcionamento de cada camada e sua função.

Dentre os desafios encontrados, destaco o uso de uma planilha Excel em vez de um arquivo CSV. A leitura do arquivo no Spark exigiu pandas + openpyxl. Como meu primeiro projeto de Engenharia de Dados de ponta a ponta, foi muito enriquecedor encontrar soluções para caminhos diferentes.

Pensando nos trabalhos futuros, acredito que automatizar a coleta dos dados brutos via API e agendar atualizações de ingestão de dados podem ser pertinentes para tornar o projeto mais eficiente. A inclusão de dados adicionais como dados de *subsurface* também trariam um elemento extra para as análises, e permitiram que elas tivessem mais profundidade nos seus entendimentos.

No geral, a atividade foi desafiadora, mas muito pertinente. Aprendi com detalhe o que acontece por trás dos dados e sua transformação, e como cada etapa do processo tem sua importância.